

E2AG: 面向事件驱动智能体操作系统的能力契约接入、策略门控与因果审计

徐刚¹, 冯骐², 姚俊杰³, 陈铭松⁴, 王江涛^{1,*}

¹ 华东师范大学国家可信嵌入式软件工程技术研究中心, 上海 (邮编待确认)

² 华东师范大学信息化治理办公室, 上海 (邮编待确认)

³ 华东师范大学软件工程学院, 上海 (邮编待确认)

⁴ 陈铭松所属单位暂缺

* 通讯作者: 王江涛, E-mail: jtwang@sei.ecnu.edu.cn

摘要

事件驱动人工智能操作系统连接外部事件、智能体运行时与工具生态, 但事件接入、任务创建和工具调用跨越多个信任边界。本文提出 E2AG (Event-to-Agent Governance): 将 Connector manifest 扩展为可执行的 source-event type 能力契约, 在 A2A Task 创建前执行目标作用域三态策略, 为任务签发短期工具授权并在 MCP 调用点再次强制, 同时用统一 `trace_id` 和哈希链接证据链记录契约、策略、调度、授权与工具结果。在作者冻结的 30 个正常和 30 个攻击事件上, 无机制、仅契约、仅策略和契约加策略的攻击阻断率分别为 0%、33.33%、66.67% 和 100%, 四组均通过 30/30 个正常事件。进一步执行 480 次真实 dispatcher、SQLite、A2A Task、ToolGrant 与 MCP PEP 路径: 双执行点同时开启时, 30/30 个正常调用到达模拟上游, 伪造来源、任务后工具升级和生产敏感动作三类禁止副作用均为 0/30; 只启用任一执行点会暴露其未覆盖阶段。5 类注入故障的 100 条持久化 trace 均定位到首个治理失败阶段并通过链校验。并发实验发现原始去重存在竞态; 引入数据库唯一去重声明后, SQLite 下 8/32 并发各 100 轮均未产生重复日志或双重审批。结果证明的是威胁驱动确定性场景中的机制闭环, 不代表任意提示词注入检测、跨数据库一致性或生产部署效果。

关键词: 人工智能操作系统; 智能体安全; 事件驱动系统; 能力契约; 策略门控; 因果审计

中图法分类号: TP309

E2AG: Capability-Contract Admission, Policy Gating, and Causal Auditing for Event-Driven Agent Operating Systems

Gang Xu¹, Qi Feng², Junjie Yao³, Mingsong Chen⁴, and Jiangtao Wang^{1,*}

¹National Trusted Embedded Software Engineering Technology Research Center, East China Normal University, Shanghai, China;

²Informationization Governance Office, East China Normal University, Shanghai, China;

³School of Software Engineering, East China Normal University, Shanghai, China

⁴Affiliation currently unavailable

(postal codes to be confirmed)

Abstract: Event-driven agent operating systems connect external events to agent runtimes and tools across multiple trust boundaries. We present E2AG (Event-to-Agent Governance), which turns connector manifests into executable source-event type contracts, performs target-scoped three-way policy decisions before A2A task creation, issues short-lived task-scoped tool grants, re-enforces them at the MCP call site, and records contract, policy, dispatch, grant, and tool outcomes in a trace-consistent hash-linked chain. In an author-frozen matrix of 30 benign and 30 attack events, attack prevention is 0%, 33.33%, 66.67%,

and 100% for no mechanism, contract only, policy only, and contract plus policy; all configurations pass 30/30 benign events. Across 480 executions using the real DiOS dispatcher, SQLite models, A2A Task, ToolGrant, and MCP PEP paths, the two-PEP configuration preserves 30/30 authorized upstream effects while each of three forbidden-effect scenarios reaches the upstream 0/30 times. One hundred persisted traces across five injected fault stages are all localized correctly and remain hash-valid. After a replay race was found, a database-unique time-bounded deduplication claim yielded no duplicate log or double approval in 8- and 32-way SQLite tests over 100 rounds each. These results establish deterministic mechanism behavior, not general prompt-injection detection, cross-database correctness, or production effectiveness.

Key words: agent operating system; agent security; event-driven system; capability contract; policy enforcement; causal audit

1 引言

智能体操作系统 (Agent OS/AIOS) 试图把模型、上下文、存储、外部工具和智能体调度从应用中抽离, 形成统一的资源与执行控制面。已有 AIOS 工作说明, 对大模型和外部工具的无限制访问会带来资源分配与潜在危害问题, 并将调度、存储与访问控制视为内核服务 [1]。与此同时, 工程系统正广泛采用 Git Webhook、电子邮件、告警、定时器及业务回调触发智能体。这使攻击者不必直接与模型对话, 只需控制智能体将要读取的事件数据, 就可能形成间接提示词注入, 并影响后续 API 或工具调用 [2]。

事件驱动链路的安全控制目前呈碎片化状态。Webhook 签名校验关注传输真实性; CloudEvents 规定 id、source、specversion 和 type 等上下文属性以实现互操作 [3]; A2A 协议通过 Agent Card 描述能力, 并用 Task 与 contextId 组织交互 [4]; 通用策略引擎把策略决策点 (PDP) 和策略执行点 (PEP) 分离 [5]; 分布式追踪规范则解决跨服务上下文传播 [6]。单独采用其中任一机制, 都无法约束一条完整的 Event-to-Agent 执行链。

本文关注如下问题: 在外部事件已经进入 AIOS、但智能体尚未开始执行的临界点, 系统如何统一约束事件声明权、目标智能体能力和高风险动作, 并保留可验证的决策因果证据? 我们的核心判断是: 事件结构不是授权, 智能体能力发现也不是调用授权, 普通可观测性 trace 更不是安全证据。三者必须在调度前形成可执行闭环。

本文提出 E2AG (Event-to-Agent Governance)。E2AG 不依赖大模型判断安全性, 而在确定性控制面完成三项工作:

1. 将 Connector manifest 中的能力声明转化为可执行的 source-event type 接入契约, 未绑定的事件默认拒绝;
2. 针对具体目标智能体, 以事件来源、类型、声明动作、请求工具和环境为上下文执行 allow、deny、approval_required 三态判定;
3. 为契约、策略、调度及 A2A Task 传播同一 trace_id, 并用前向哈希链接形成可校验的因果证据链。

本文的贡献如下:

- 提出 Event-to-Agent 跨层威胁模型, 区分事件格式合规、来源声明权、目标能力授权和执行证据完整性;
- 设计“契约接入—策略门控—因果审计”统一控制链, 并说明三项机制的职责边界;
- 在 DiOS 最新开发基线上实现调度前强制点、三态决策、审计持久化与 A2A trace 传播, 提供不依赖模型的确定性测试;
- 在 60 例冻结威胁矩阵上完成 Contract×Policy 2×2 消融, 并以 480 次持久化 Event-to-Agent-to-Tool 执行、100 条因果定位 trace 和并发竞态实验验证双执行点与审计闭环。

上述工作直接面向专刊所列“智能体协同安全与调度防护机制”问题: 契约和策略决定事件能否进

入调度, 因果审计则为调度防护的度量、异常分析与复核提供证据。

2 背景与问题定义

2.1 DiOS 事件控制面

DiOS[7] 与 DiAgent 在 DiFlow 工具链中承担不同职责: DiOS 管理 Agent、模型、MCP、Connector 等资源, 并负责事件接入、路由、任务调度和执行追踪; DiAgent 负责单个智能体的模型、上下文、Skill 与工具交互。因而本文把 DiOS 视为一个正在演进的事件驱动 Agent 控制面原型, 而非已经完备的企业级 AIOS。该定位既解释了 E2AG 的系统落点, 也避免把未来 Roadmap 能力写成当前事实。

当前开发分支已经包含 Connector manifest/registry、CloudEvents 标准化、事件去重、订阅匹配、重试和 A2A Task。EventLog 表示事件, A2ATask 表示一次智能体调用, 两者通过 `context_id=EventLog.id` 关联。Connector 覆盖 GitHub/GitLab/Gitea、IMAP、通用 Webhook, 以及 Cron/Manual 内建事件; task-mode Agent 由隔离的 DiAgent 运行时执行, 并可获得系统分配的 MCP 配置。

这一基线具备实现 E2AG 的关键“窄腰”: 所有事件最终都在 dispatcher 创建 A2A Task。将第一个 PEP 设置于此, 可覆盖 Webhook、轮询和内建事件, 且无需侵入每个 Connector; 将第二个 PEP 设置于远程 MCP 调用点, 可在工具产生副作用前重新校验任务授权。但基线 manifest 只面向展示和订阅声明事件类型, 尚不能强制判断一个 `source` 与一个 `type` 是否属于同一 Connector 契约; `Agent.capabilities` 也未参与事件投递授权。图 1 给出本文所涉及的 DiOS 子架构与 E2AG 落点。




图 1: DiOS 事件驱动智能体控制面及 E2AG 治理落点

图中灰色节点是当前 DiOS/DiAgent 基线, 蓝色节点是 E2AG 新增或强化的治理机制, 虚线节点表示 Roadmap 或本文尚未统一中介的路径。跨域箭头对应外部输入、控制面到运行时、运行时到工具三类信任边界。该图只说明论文相关的系统上下文, 不把 DiOS 管理界面、模型服务和全部应用层能力列为本文贡献。

2.2 格式、能力与授权的差异

CloudEvents 解决的是事件描述与互操作问题。其 `source` 标识事件发生上下文, `type` 描述事件类型, `source+id` 可供消费者识别重复事件。然而, 一个结构正确的 CloudEvent 不等于来源有权声明任

意 `type`。例如, `source=webhook/attacker` 与 `type=git.push` 可以同时满足字段类型要求, 却不应触发只信任 Git Connector 的智能体。

A2A Agent Card 描述身份、能力、技能、端点与认证需求, `contextId` 用于把多个 Task/Message 组织为逻辑上下文。这些信息有利于发现和连续交互, 但“声称支持能力”仍不等于“当前事件获准使用能力”。E2AG 因而把发现信息转换成目标作用域的运行时约束。

2.3 安全目标

设事件为 e , 目标智能体集合为 A_e , Connector 能力契约集合为 C , 策略集合为 P 。E2AG 要求在创建任何任务之前满足:

$$\text{Admit}(e, A_e) = \text{Bound}(e, C) \wedge \text{Permit}(e, A_e, P).$$

若 **Bound** 为假, 事件必须拒绝; 若 **Permit** 判断为高风险且可审批, 事件进入等待态; 只有两者均允许才创建 A2A Task。系统同时生成证据序列 $L = (l_0, \dots, l_n)$, 其中每一项包含相同 `trace_id`, 并满足:

$$h_i = H(\text{canon}(l_i \setminus \{h_i\})), \quad l_i.\text{previous_hash} = h_{i-1}, \quad h_{-1} = \epsilon.$$

审计校验器检查序号、`trace` 连续性、前驱哈希与内容哈希。该结构提供链内篡改检测, 但数据库管理员仍可能整体删除或回滚整条链; 外部锚定属于未来工作。

3 威胁模型

3.1 攻击者能力

攻击者可提交或影响 Webhook、邮件、Git 内容和通用事件载荷; 可构造结构化字段和自然语言; 可重放已观察事件; 可利用订阅通配符; 也可诱导智能体请求未授权工具或生产资源。攻击者不能直接修改 DiOS 进程内策略、目标智能体治理配置或数据库代码, 但可能尝试通过事件内容混淆这些边界。

3.2 保护对象与信任边界

保护对象包括 Connector 凭据、Agent Prompt/模型/Skill/MCP、工作区、生产网络、Secret、执行产物和审计记录。主要边界位于外部系统与 Connector、Connector 与 Event Gateway、Gateway 与 dispatcher、dispatcher 与 A2A/Runtime、Runtime 与模型/工具之间。

3.3 攻击类别

- 来源—类型混淆: 用合法字段组合伪造未绑定的 `source/type`;
- 跨租户或跨项目路由: 合法 Git 事件来自未授权组织, 却匹配过宽订阅;
- 动作与工具越权: 低风险事件请求 `shell`、管理、Secret 或生产写能力;
- 意图缺失: 载荷只有自然语言指令, 没有可供控制面授权的结构化动作;
- 高风险副作用: 删除、凭据轮换或生产网络写入未经人工确认;
- 审计断链: 修改中间决策或使 EventLog 与 A2ATask 丢失关联。

E2AG 当前不试图从任意自然语言中准确识别恶意语义。若攻击者声明一个获准动作, 同时把注入内容隐藏在业务数据中, 控制面只能限制其可达的智能体、工具和动作; 仍需工具调用时 PEP、数据流控制或模型侧防御。这一限制在实验解释中单独报告。

4 E2AG 设计

4.1 执行流程




图 2: E2AG 的双执行点治理流程

原型的契约计算和订阅匹配均无外部副作用；实际强制点位于 dispatcher 开头、A2A Task 创建之前。这意味着订阅匹配可能先计算候选目标，但任何智能体执行仍必须经过 E2AG。

4.2 能力契约接入

E2AG 在 Connector manifest 中新增可接受 source pattern。运行时将其与 event type 做笛卡尔绑定；内建/场景 namespace 则沿用显式 source-event type 对。契约判定首先验证 DiOS 所需字段 specversion/id/source/type/data，再查找唯一可接受绑定。当前 Git、IMAP、Generic 与 Internal 合同示例如下：

Connector	可接受 source	可接受 type 示例
git_webhook	github/*, gitlab/*, gitea/*	git.push, git.issue.*, git.pull_request.*
imap	imap/*	email.received
generic	webhook/*	webhook.received
internal	manual/*, cron/*	manual.trigger, cron.tick

契约输出包含 decision、稳定 reason code、contract type、匹配 pattern、策略版本和判定延迟。实现采用默认拒绝：结构异常、规范版本异常、未知类型或未绑定组合均不可进入 Agent。

4.3 目标作用域策略门控

每个 Agent 可在现有 capabilities.governance 中声明：

```

{
  "allowed_event_sources": ["github/acme/*"],
  "allowed_event_types": ["git.pull_request.*"],
  "allowed_tools": ["git.read", "git.comment"],
  "allowed_actions": ["git.review"],
  "require_action_declaration": true
}
  
```

PEP 加载所有候选 Agent 的治理声明并进行合取判定。目标 Agent 完全缺失治理能力声明时默认拒绝；已有治理对象中缺失的单个维度暂不施加限制，已声明列表则具有 allow-list 语义。严格模式要求载荷给出结构化动作。生产环境中的 admin、credential、secret、文件删除和生产网络写等动作返回 approval_required。三态结果被持久化，不把待审批事件误当作失败事件重试。每个待审批事件生成一个有时限的 Approval；其状态只能从 pending 单次转移为 approved、rejected 或 expired。只有批准分支复用原 EventLog 的 trace_id 恢复 A2A fan-out，拒绝、过期和重复决策均不创建任务。

原型提供 off、contract、enforce 三种运行模式以支持消融。未知模式回退到 enforce，避免配置错误导致静默放行。

策略门控不是一次性接入判断。对于事件触发的 task-mode Agent，原型把远程 streamable HTTP MCP 配置改写到 DiOS 内部 PEP，并签发绑定 trace、task、agent、MCP server 和 allowed tools 的短期 ToolGrant。数据库只存授权令牌 SHA-256 摘要；任务完成、失败或取消时撤销授权，过期或任务绑定不一致的令牌在调用点拒绝。tools/list 响应也按授权模式裁剪，避免先暴露完整工具面。任何越权 tools/call 在接触上游及其长期凭据前被拒绝并写入同一审计链。

4.4 因果审计

每个 EventLog 生成 128 bit 随机 trace_id。该标识写入 EventLog、A2ATask 和发送给 Agent 的 A2A message 扩展。审计链至少包含 contract、policy 和 dispatch 三个阶段；创建任务后再记录 task_id 与 agent_id。每个条目包含 sequence、stage、outcome、evidence、previous_hash 与 entry_hash。验证函数可发现内容、顺序、trace 或前驱链接的修改。

被拒绝与待审批事件同样创建 EventLog，但不创建 A2ATask；这既保留攻击证据，也使“审计成功”与“执行发生”解耦。数据库迁移为历史 SQLite 增加相应 JSON/text 字段和 trace 索引。

5 原型实现

E2AG 在 DiOS 后端以一个无副作用判定模块实现，核心代码不依赖 SQLAlchemy、FastAPI 或模型 SDK，便于单元测试、重放和微基准。dispatcher 负责加载目标 Agent 能力、调用判定、持久化审计及阻断 A2A fan-out。A2A service 新增可选 trace_id 参数，并保证 Task、协议返回和 message 扩展的一致传播。

当前实现新增或修改的主要组件如下：

组件	实现内容
connectors/contracts.py	source-type 可执行契约字段
services/e2ag.py	纯函数契约/策略判定与哈希链校验
services/event_dispatcher.py	A2A 创建前 PEP、三态阻断与审计
services/a2a_service.py	trace 贯通 A2ATask 和 message
services/e2ag_tool_gateway.py	任务作用域 ToolGrant、MCP 方法/工具授权与撤销
services/e2ag_approval.py	有时限、单次消费的批准/拒绝/过期状态机
api/internal/e2ag_mcp.py	远程 streamable HTTP MCP 执行点 PEP 与工具发现裁剪
models/tables.py, db/database.py	审计持久化与兼容迁移
tests/test_e2ag*.py	决策与真实异步 SQLite 集成测试
experiments/e2ag	攻击夹具、消融和微基准脚本

截至本稿, 30 个自动测试全部通过。其中 12 个覆盖纯判定和哈希篡改, 6 个覆盖真实异步 SQLite dispatcher/A2A 路径 (含相同事件 replay 去重), 9 个覆盖工具网关及其任务生命周期, 3 个覆盖审批状态机。后两组验证拒绝调用不会到达 mocked upstream、授权调用才携带上游凭据转发、工具发现结果按能力裁剪且畸形响应默认返回空列表、令牌只存哈希且具有任务绑定/到期/撤销语义、任务专用明文令牌配置被精确清理, 以及审批拒绝不可翻转、过期不可恢复、批准沿同一 trace 只恢复一次 fan-out。

6 实验设计

6.1 研究问题

- **RQ1:** source-type 契约与目标作用域策略是否分别贡献安全收益, 组合后是否互补?
- **RQ2:** 调度前 PEP 与 MCP 调用时 PEP 是否能在真实持久化执行链中共同阻止禁止副作用?
- **RQ3:** 统一 trace 和哈希链能否完整关联执行阶段并定位治理失败点, 其并发状态不变量是否成立?

6.2 对照与数据集

RQ1 使用完整 2×2: C0P0 (契约、策略均关闭)、C1P0 (仅契约)、C0P1 (仅策略) 和 C1P1 (均开启)。正式冻结集为 60 例, 其中 30 个正常事件、30 个攻击事件; 攻击包括 10 个 source-type 绑定攻击、16 个目标 source/type/action/tool 或意图攻击, 以及 4 个应转审批的生产敏感动作。语料覆盖 GitHub、GitLab、Gitea、IMAP、通用 Webhook、Manual 和 Cron, SHA-256 前后缀为 8c0074fc...a096a6。所有事件均满足基本结构要求, 以隔离 source-type 绑定与目标策略贡献。该语料是作者冻结威胁矩阵, 独立合作者标签复核尚待完成。

RQ2 使用 G0R0、G1R0、G0R1、G1R1 四组, G 表示调度前 PEP, R 表示 MCP 调用时 PEP。四类场景为正常授权调用、伪造来源、任务创建后的工具升级和生产敏感动作, 每个“配置 × 场景”重复 30 次, 共 480 次。执行使用真实 DiOS dispatcher、SQLite 模型、A2A Task、ToolGrant、MCP PEP 和审计链; Agent 决策和远程 MCP 为确定性测试替身, 不使用 LLM、容器和外部网络。主要观测上游是否真正收到调用及 canary 副作用是否发生, 而非只读取授权函数返回值。

6.3 指标与环境

RQ1 报告攻击阻断率、正常通过率、各治理层计数和 Wilson 95% 置信区间。RQ2 报告 Task/Approval/Grant 创建数、上游调用数、允许/禁止副作用数、审计链有效性和路径阶段完整性。RQ3 对契约拒绝、策略拒绝、审批过期、ToolGrant 过期、MCP 工具拒绝各注入 20 次, 报告阶段定位、trace 完整性和哈希校验; 另对 8/32 并发 replay 与 approve/reject 各运行 100 轮。性能仅作为同机随机配对的工程观察: 30 批、每批 1200 次判定, 不作为独立研究问题或生产性能证据。

7 实验结果

7.1 RQ1: Contract×Policy 完整消融

模式	阻断攻击	攻击阻断率	正常通过	正常通过率
C0P0	0/30	0.00%	30/30	100.00%
C1P0	10/30	33.33%	30/30	100.00%
C0P1	20/30	66.67%	30/30	100.00%

模式	阻断攻击	攻击阻断率	正常通过	正常通过率
C1P1	30/30	100.00%	30/30	100.00%

C1P0 只阻断 10 个契约绑定攻击；C0P1 阻断 16 个目标能力攻击，并将 4 个生产敏感动作转为待审批；C1P1 合并两类控制点。对应 Wilson 95% 区间分别为 [19.23%, 51.22%]、[48.78%, 80.77%] 和 [88.65%, 100%]；30/30 正常通过的区间为 [88.65%, 100%]。结果支持机制分工，但作者冻结矩阵不是未知攻击样本。

7.2 RQ2: 双执行点与上游副作用

配置	正常到达	伪造来源副作用	工具升级副作用	敏感动作副作用
G0R0	30/30	30/30	30/30	30/30
G1R0	30/30	0/30	30/30	0/30 (审批)
G0R1	30/30	30/30	0/30	0/30
G1R1	30/30	0/30	0/30	0/30 (审批)

调度前 PEP 能阻断伪造来源并把高风险动作转为审批，但不能阻止任务创建后的工具升级；MCP PEP 能阻断未授权工具，却无法判断获准工具是否由伪造来源触发。G1R1 保持 30/30 个正常副作用，并使三类禁止副作用均为 0/30。480/480 条链通过哈希校验且包含路径所需阶段。确定性 Agent/MCP 替身证明系统强制路径，而非 LLM 识别恶意语义的能力。

7.3 RQ3: 因果阶段定位

注入故障	trace 数	正确定位	链有效	阶段完整
契约拒绝	20	20	20	20
策略拒绝	20	20	20	20
审批过期	20	20	20	20
ToolGrant 过期	20	20	20	20
MCP 工具拒绝	20	20	20	20

100/100 条 trace 均使用同一 `trace_id`，包含预期阶段并定位到首个终态治理失败点。该定位依赖显式 stage/outcome 语义，不等同于一般程序根因分析。6 类链内篡改均能检出；无外部 head/count 锚点时链尾截断仍不可检测。

7.4 并发 replay 与审批竞态

修复前，8 并发 replay 的 100/100 轮均持久化多条 EventLog，共创建 588 条日志而不是 100 条，暴露 check-then-insert 竞态。原型随后增加数据库唯一、带过期时间的 EventDedupClaim。修复后结果如下：

场景	并发	轮数	请求数	创建/成功终态	不变量违规
replay	8	100	800	100	0

场景	并发	轮数	请求数	创建/成功终态	不变量违规
replay	32	100	3200	100	0
approve/reject	8	100	800	100	0
approve/reject	32	100	3200	100	0

该结果只验证 SQLite 文件数据库与独立异步会话，不外推其他数据库或多地域部署。修复前 32 并发数据因实验输入与前一阶段哈希碰撞而无效，不用于结论。

7.5 附属开销观察

同机随机配对 30 批中，C1P1 每次判定的批次均值中位数为 11.228 μ s，P95 为 12.896 μ s。C0P0 近似空函数，故不报告容易误导的相对倍数。该观察仅排除纯判定出现数量级退化，不支持生产端到端性能结论。

8 讨论与限制

语义攻击。E2AG 不是提示词注入分类器。结构化意图和能力 allow-list 可降低攻击可达面，运行时 MCP PEP 可阻止模型越出获准工具集合；但恶意载荷若诱导同一个已授权工具使用危险参数，当前工具名粒度策略仍可能放行，后续需加入参数级谓词与数据流约束。

可信声明。当前动作和工具字段随事件数据到达，攻击者可以伪造声明。严格模式要求提供结构化动作，以防止完全隐式意图；但声明本身仍需与具体 handler/skill 绑定，不能只依赖事件自述。论文后续将区分“不可信请求意图”和“系统推导的计划动作”。

审批身份。原型已实现批准、拒绝、过期与数据库条件更新支持的单次消费状态机；但审批 API 沿用 DiOS 可选 Access Token 门禁，actor 是客户端提交的审计字段，尚未接入独立身份提供方、RBAC、多人复核或职责分离。因此本文主张的是可审计的 HITL 状态机，不是强身份审批系统。

工具传输覆盖。当前执行点 PEP 仅覆盖事件触发的 task-mode Agent 与远程 streamable HTTP MCP。为维持默认拒绝，enforce 模式不把 stdio 或 SSE MCP 下发给这类任务；service-mode Agent、Skill 内部调用、MCP 流式响应背压、工具参数授权及独立 Agent 运行时中的旁路调用尚未完成统一中介。因此当前不能声称覆盖 DiOS 的所有工具执行路径。

审计强度。哈希链可检测链内修改，但无法抵御高权限管理员删除整条记录、截断尾部或回滚数据库。可采用外部透明日志、周期 Merkle root 锚定或签名存储增强不可抵赖性。

外部有效性。当前实现在单一开源系统上完成，60 例语料是作者冻结的威胁驱动矩阵，独立合作者标签复核仍待完成；确定性 Agent/MCP 测试替身不能替代真实 LLM 红队、生产凭据与外部网络。并发结果只验证 SQLite，其他数据库和多实例部署尚未实测。固定种子 700 次变异去重后只有 319 个不同用例，因此仅作为机制覆盖附录，不作为独立样本规模。

9 相关工作

AIOS 将智能体所需的模型、工具、上下文和资源管理下沉到类似操作系统内核的控制层，为 E2AG 提供了系统落点。间接提示词注入研究表明，攻击者可在被应用检索或处理的数据中植入指令，并影响外部 API 调用，这构成事件载荷威胁的重要依据。

CloudEvents 提供跨平台的事件格式与必要上下文属性，但不规定某一来源对某一领域事件类型的授权关系。A2A 提供 Agent Card、Message、Task、Artifact 和 contextId 等互操作抽象；E2AG 在

其上补充事件到任务创建前的授权与安全 trace。OPA 明确区分 PDP 和 PEP，并支持对结构化输入作策略决策与审计日志；E2AG 沿用此职责分离，但当前采用内置确定性规则，贡献不依赖具体策略引擎。W3C Trace Context 解决分布式请求的统一 trace 传播；E2AG 进一步把安全决策与哈希证据链接入 trace，但不替代通用可观测性标准。

10 结论

本文提出 E2AG，将事件能力契约、目标作用域策略门控、任务作用域工具授权和哈希链接因果审计部署在 Event-to-Agent 执行链的两个临界点。60 例 Contract×Policy 完整消融显示两类控制点在冻结威胁矩阵上互补；480 次持久化执行说明调度前 PEP 和 MCP PEP 分别约束事件入口与实际工具副作用；100 条注入故障 trace 验证了显式治理阶段的关联和定位。并发实验还发现并修复了 replay 去重竞态。上述证据支持确定性原型机制闭环，不支持任意提示词注入检测、跨数据库正确性或生产部署泛化；参数级策略、完整传输覆盖、外部审计锚定和跨 AIOS 验证仍是后续工作。

参考文献

- [1] Mei K, Zhu X, Xu W, et al. AIOS: LLM Agent Operating System. arXiv:2403.16971, 2024.
- [2] Greshake K, Abdelnabi S, Mishra S, et al. Not What You've Signed Up For: Compromising Real-World LLM-Integrated Applications with Indirect Prompt Injection. arXiv:2302.12173, 2023.
- [3] Cloud Native Computing Foundation. CloudEvents Specification, Version 1.0. <https://github.com/cloudevents/spec/blob/main/cloudevents/spec.md>.
- [4] A2A Protocol Working Group. Agent2Agent Protocol Specification. <https://a2a-protocol.org/latest/>.
- [5] Open Policy Agent. OPA Documentation: Policy Decision and Enforcement. <https://www.openpolicyagent.org/docs>.
- [6] W3C. Trace Context. W3C Recommendation, 2021. <https://www.w3.org/TR/trace-context/>.
- [7] HQIT. DiOS: DiFlow Intelligent Operation System. <https://github.com/HQIT/DiOS>.
- [8] 《软件学报》编辑部. “人工智能操作系统及其安全” 专刊征文, 2026.